

Dossier de conception

Analyse conceptuelle UML et Merise – Système RAG pour hcp.ma

Structure d'accueil : Haut-Commissariat au Plan (HCP), Direction des Systèmes
d'Information Statistiques

Binôme : Ayman El Baida et Saad Mesbah

Période du stage : 1er juillet – fin août 2026

Document complémentaire à la fiche de cadrage – phase conception

Table des matières

1	Introduction	2
2	Diagramme de cas d'utilisation	2
3	Modèle conceptuel de données (MCD)	2
4	Modèle logique de données (MLD)	3
5	Diagramme de classes	4
6	Diagramme de séquence – question chiffrée	4
7	Diagramme de séquence – question conceptuelle	6
8	Diagramme d'activité – pipeline d'ingestion	6
9	Synthèse	7

1 Introduction

Ce document prolonge la fiche de cadrage en formalisant, selon la démarche UML et Merise, l'analyse conceptuelle du système de questions-réponses (RAG) pour hcp.ma. Sept diagrammes y sont présentés : le diagramme de cas d'utilisation, le modèle conceptuel de données (MCD) et sa traduction logique (MLD), le diagramme de classes, deux diagrammes de séquence illustrant les deux chemins de traitement du système, et un diagramme d'activité décrivant le pipeline d'ingestion. Chaque diagramme est accompagné d'une analyse qui explique son contenu et le relie aux choix architecturaux déjà justifiés dans la fiche de cadrage.

2 Diagramme de cas d'utilisation

Ce diagramme fixe le périmètre fonctionnel du système en identifiant les acteurs et leurs interactions, avant toute considération technique.




Figure 1 – Diagramme de cas d'utilisation du système RAG hcp.ma

Analyse


Deux acteurs sont identifiés. L'**Utilisateur**, représentant le grand public visiteur de hcp.ma, interagit avec le système pour poser une question en langage naturel, consulter une réponse sourcée, et donner un retour sur cette réponse. L'**Administrateur**, rattaché au service SI, dispose de cas d'utilisation distincts : mettre à jour le contenu indexé, consulter l'historique des questions posées, et superviser la fiabilité du système. Cette séparation des rôles montre que le système doit exposer deux niveaux d'interaction : une interface publique simple et une interface de gestion plus technique. Ce diagramme découle directement des besoins fonctionnels F1 à F6 définis dans la fiche de cadrage et en constitue la traduction visuelle formelle.

3 Modèle conceptuel de données (MCD)

Le MCD formalise la partie strictement relationnelle du système, selon la méthode Merise.

Modele conceptuel de donnees (MCD) - perimetre relationnel

(l'index vectoriel des embeddings n'est pas represente ici : ce n'est pas une structure relationnelle)



Lecture : un DOCUMENT contient de 0 à N CHUNK ; un CHUNK appartient à exactement 1 DOCUMENT.
Un DOCUMENT est source de 0 à N INDICATEUR ; un INDICATEUR provient d'exactly 1 DOCUMENT.

Figure 2 – MCD des entités DOCUMENT, CHUNK et INDICATEUR

Analyse

Trois entités structurent ce modèle : DOCUMENT, CHUNK et INDICATEUR. Deux associations les relient. L'association « contient » entre DOCUMENT et CHUNK porte la cardinalité (0,N) côté document et (1,1) côté chunk : un document peut contenir de 0 à N fragments de texte, mais un fragment appartient toujours à exactement un document. L'association « est source de » entre DOCUMENT et INDICATEUR suit la même logique : un document peut être à l'origine de plusieurs indicateurs chiffrés, mais chaque indicateur provient d'un document unique, traçable.

Un point méthodologique important apparaît ici : l'index vectoriel des embeddings, bien que central dans l'architecture générale du système, n'apparaît volontairement pas dans ce MCD. Un vecteur de similarité sémantique ne se prête pas à une modélisation entité-association classique ; il s'agit d'une structure technique de nature différente, déjà décrite dans le modèle de données de la fiche de cadrage. Cette limite assumée du MCD reflète une application rigoureuse de la méthode Merise plutôt qu'un oubli : on ne force pas dans un formalisme relationnel une structure qui ne l'est pas.

4 Modèle logique de données (MLD)


Le MLD traduit le MCD en schéma de tables directement implémentable.

Analyse

Chaque entité du MCD devient une table SQL dotée d'une clé primaire (PK). Les associations se traduisent par des clés étrangères : la colonne **id_document** apparaît à la fois dans **CHUNK** et dans **INDICATEUR**, référençant la table **DOCUMENT**. Cette contrainte d'intégrité référentielle garantit que chaque fragment de texte et chaque indicateur reste traçable jusqu'à son document source : c'est la condition technique nécessaire à la citation systématique des sources exigée par le besoin fonctionnel F3

Modele logique de donnees (MLD)

Traduction du MCD en tables SQL - PK = cle primaire, FK = cle etrangere



Les fleches en pointille relient chaque cle etrangere (FK) a la cle primaire (PK) qu'elle reference.

Figure 3 – MLD : tables *DOCUMENT*, *CHUNK* et *INDICATEUR* avec clés primaires et étrangères

et l'exigence non fonctionnelle NF3 de la fiche de cadrage. Ce MLD peut être implémenté directement en SQLite ou PostgreSQL sans transformation supplémentaire.

5 Diagramme de classes

Ce diagramme transpose les neuf modules du système, déjà décrits sous forme de tableau dans la fiche de cadrage, en classes logicielles.

Analyse

Chaque classe porte une responsabilité unique : **Scraper** collecte, **Extracteur** nettoie et sépare, **IndexeurTexte** et **ConstructeurIndicateurs** indexent chacun selon la nature du contenu, **Routeur** aiguille, **RetrievalReranker** et **LookupStructure** récupèrent l'information selon le chemin choisi, **Generateur** rédige, et **Interface** affiche. Les flèches représentent les dépendances d'utilisation et matérialisent le flux de données de bout en bout, avec la bifurcation caractéristique de l'architecture entre traitement du texte et traitement des données chiffrées, visible à deux reprises dans le diagramme (après **Extracteur** et après **Routeur**). Cette décomposition modulaire permet au binôme de répartir le développement par classe sans dépendance circulaire entre les deux membres.

6 Diagramme de séquence – question chiffrée

Ce diagramme illustre, message par message, le chemin de traitement d'une question portant sur une valeur précise.

Analyse

La caractéristique essentielle de ce scénario est l'absence de génération libre : après que le **Routeur** a classé la question comme portant sur un chiffre, le **LookupStructure** exécute une requête directe sur la table **INDICATEUR** et renvoie une valeur exacte accompagnée de sa source. Le **Generateur** n'intervient qu'en toute fin de chaîne pour mettre cette valeur en forme dans une phrase, sans marge

Diagramme de classes (composants logiciels)




Figure 4 – Diagramme de classes des composants logiciels

Diagramme de sequence - question chiffrée

Exemple : "Quel est le taux de chômage actuel ?




Figure 5 – Scénario « Quel est le taux de chômage actuel ? »

d'interprétation sur le chiffre lui-même. C'est ce chemin, distinct du second scénario, qui élimine le risque d'hallucination sur les chiffres officiels et répond à l'exigence non fonctionnelle NF2 (exactitude factuelle supérieure ou égale à 90 %).

7 Diagramme de séquence – question conceptuelle

Ce second diagramme illustre le chemin emprunté pour les questions explicatives ou méthodologiques.




Figure 6 – Scénario « C'est quoi le RGPH ? »

Analyse

Contrairement au premier scénario, la réponse n'est pas une valeur unique récupérée par requête exacte, mais une synthèse construite à partir de plusieurs passages textuels. Le **RetrievalReranker** interroge l'**IndexTexte** par recherche hybride (sémantique et lexicale), puis retient les passages candidats pour ne garder que les plus pertinents avant de les transmettre au **Generateur**. La comparaison directe des figures 5 et 6 met en évidence la différence de traitement entre les deux types de questions : c'est cette bifurcation, décidée par le **Routeur** dès la réception de la question, qui constitue le cœur de l'architecture proposée dans la fiche de cadrage.

8 Diagramme d'activité – pipeline d'ingestion

Ce diagramme modélise le processus d'ingestion du contenu, en amont de toute interaction avec un utilisateur.

Analyse

À la différence des deux diagrammes de séquence précédents, ce diagramme représente un traitement par lot (batch) et non une interaction en temps réel avec un utilisateur : c'est pourquoi il est modélisé en diagramme d'activité plutôt qu'en diagramme de séquence, les deux formalismes n'ayant pas la même vocation. Le point de décision « Type de contenu ? » matérialise la bifurcation entre les deux natures de contenu identifiées dès la problématique du projet : le texte narratif suit un chemin de découpage, d'embedding puis d'indexation hybride, tandis que les tableaux de chiffres suivent un




Figure 7 – Pipeline d'ingestion, de la collecte à l'indexation

chemin d'extraction directe vers la table indicateurs. La barre de synchronisation en fin de diagramme indique que les deux branches doivent être complètes avant que le contenu ne soit considéré comme intégralement disponible pour répondre aux questions.

9 Synthèse

Les sept diagrammes présentés dans ce dossier couvrent l'ensemble des angles nécessaires à une analyse conceptuelle rigoureuse : le périmètre fonctionnel (cas d'utilisation), la structure des données relationnelles (MCD, MLD), l'architecture logicielle (classes), le comportement dynamique du système face à l'utilisateur (séquences) et le processus de préparation des données (activité). Cette analyse valide, sous une forme formelle et normalisée, les choix déjà justifiés dans la fiche de cadrage – en particulier la séparation stricte entre traitement du texte et traitement des données chiffrées, qui demeure le fil conducteur de l'ensemble des diagrammes. Le binôme dispose à présent d'une base suffisamment formalisée pour engager la phase de réalisation.