

Fiche de cadrage détaillée

Système de questions-réponses (RAG) pour le site institutionnel hcp.ma

Structure d'accueil : Haut-Commissariat au Plan (HCP), Direction des Systèmes
d'Information Statistiques

Binôme : Ayman El Baida et Saad Mesbah

Période du stage : 1er juillet – fin août 2026

*Document rédigé le 7 juillet 2026 – support pour le rapport de stage et la communication du
projet*

Table des matières

1	Présentation de l'organisme d'accueil	2
2	Nature et périmètre du projet	2
2.1	Périmètre retenu	2
2.2	Hors périmètre pour cette première itération	2
3	Contexte et problématique	3
4	Enjeux du projet	3
4.1	Enjeux pour le HCP	3
4.2	Enjeux pour le binôme	3
5	Objectifs	3
5.1	Objectifs spécifiques	3
6	Besoins fonctionnels et non fonctionnels	4
6.1	Besoins fonctionnels	4
6.2	Besoins non fonctionnels	4
7	Méthodes et démarche	4
7.1	Démarche de gestion de projet	4
7.2	Méthodes techniques envisagées	5
8	Conception première (architecture)	5
8.1	Détail des modules	5
8.2	Modèle de données	6
8.3	Scénarios d'exécution (exemples)	7
8.4	Choix technologiques proposés	7
8.5	Points de robustesse à prévoir	7
9	Analyse des risques	7
10	Critères de réussite	8
11	Hypothèses de travail et points à valider	8
12	Planning proposé	9
13	Glossaire	9

1 Présentation de l'organisme d'accueil

Le Haut-Commissariat au Plan (HCP) est l'institution marocaine chargée de la production statistique officielle, de la planification, de la prospective, de l'analyse et de la prévision économique du Royaume du Maroc. Ses domaines de compétence couvrent notamment la démographie et les recensements généraux de la population et de l'habitat (le dernier RGPH, réalisé en 2024, dénombant une population légale de 36 828 330 habitants), les comptes nationaux et la conjoncture économique, le marché du travail (activité, emploi, chômage), les indices des prix et de la production, le suivi des objectifs de développement durable (ODD), et le nouveau modèle de développement.

Le stage se déroule au sein de la Direction des Systèmes d'Information Statistiques, la direction en charge de l'infrastructure numérique et de la valorisation technologique des données produites par le HCP – un positionnement particulièrement pertinent pour un projet d'intelligence artificielle appliqué à la diffusion de l'information statistique officielle.

2 Nature et périmètre du projet

Ce projet s'inscrit dans le cadre d'un stage mené au sein de la Direction des Systèmes d'Information Statistiques du HCP. Il s'agit d'un projet de recherche appliquée visant à concevoir et développer un prototype fonctionnel de système de question-réponse fondé sur la génération augmentée par récupération (Retrieval-Augmented Generation, RAG), exploitant le contenu du site institutionnel hcp.ma. Le projet est mené en binôme, sur une durée resserrée de 4 à 8 semaines, avec un objectif de livraison d'un prototype démontrable début août et une marge de sécurité jusqu'à fin août.

2.1 Périmètre retenu

- Contenu source : sélection ciblée de catégories du site (publications et notes d'information des rubriques Économie, Marché du travail, Population & démographie ; glossaire « Concepts et définitions » ; foire aux questions ; un ensemble curaté d'indicateurs clés – chômage, inflation, PIB, population).
- Langue : français en priorité pour le prototype ; l'arabe est une extension possible si le calendrier le permet.
- Utilisateurs ciblés : conçu pour le grand public visiteur de hcp.ma, transposable à un usage interne aux agents du HCP.
- Livrable attendu : un prototype fonctionnel documenté, accompagné d'une évaluation de fiabilité.

Mise à jour (03/09/2026) : Le projet a finalement été mené en solo par Ayman El Baida, et non en binôme comme prévu à la page de titre de ce document (rédigée le 7 juillet, reflétant la situation de départ). Voir le rapport de stage pour le détail.

2.2 Hors périmètre pour cette première itération

- Crawl exhaustif de l'intégralité du site hcp.ma.
- Support arabe complet dès la première version.
- Infrastructure de production sécurisée ou hébergement souverain on-premise.
- Intégration dans les applications web dynamiques existantes (comptes nationaux, simulateurs, résultats RGPH 2024).

3 Contexte et problématique

Le site hcp.ma centralise un volume important d'informations statistiques officielles, mais sous des formats hétérogènes : pages HTML éditoriales, documents PDF souvent bilingues (français/arabe), glossaire de concepts, foire aux questions, et données chiffrées structurées (indicateurs, séries temporelles, micro-données). Un usager – citoyen, chercheur, journaliste ou agent du HCP – qui cherche une information précise doit aujourd'hui naviguer manuellement dans cette architecture ou utiliser une recherche par mots-clés, laquelle ne comprend pas les questions formulées en langage naturel et ne permet pas de croiser plusieurs sources pour construire une réponse.

Un chatbot fondé sur un LLM générique résoudrait le problème de compréhension du langage naturel, mais introduit un risque inacceptable pour un institut statistique officiel : l'hallucination, c'est-à-dire la génération d'un chiffre plausible mais faux, non vérifié face aux sources. La problématique centrale du projet est donc la suivante :

Comment concevoir un système de question-réponse qui exploite le contenu du site du HCP de façon fiable et traçable, en tenant compte de la double nature du contenu : texte narratif d'une part, données chiffrées structurées d'autre part ?

4 Enjeux du projet

4.1 Enjeux pour le HCP

Moderniser l'accès à un patrimoine statistique riche mais dispersé sur des centaines de pages et de publications ; réduire la charge de traitement des demandes répétitives d'information ; valoriser numériquement des décennies de production statistique auprès du grand public, des chercheurs et des décideurs.

4.2 Enjeux pour le binôme

Monter en compétence sur une chaîne complète de traitement du langage naturel appliqué (RAG, recherche hybride, évaluation de fiabilité) sur un cas d'usage réel à enjeu de fiabilité critique – une expérience directement valorisable pour la suite du parcours (CV, poursuite d'études, marché du travail de l'intelligence artificielle appliquée).

5 Objectifs

Objectif général : concevoir et développer un prototype de système RAG capable de répondre en langage naturel à des questions portant sur les statistiques et publications du HCP, avec une garantie de traçabilité des sources et un contrôle de la fiabilité factuelle des réponses.

5.1 Objectifs spécifiques

- Construire un pipeline d'ingestion et d'extraction pour les catégories de contenu ciblées (HTML, PDF, données tabulaires).
- Mettre en place une indexation hybride : recherche vectorielle et recherche lexicale (BM25) pour le contenu textuel, et une base structurée dédiée pour les indicateurs chiffrés.
- Développer un mécanisme de routage distinguant les questions relevant d'un chiffre précis de celles relevant d'une explication conceptuelle ou narrative.
- Garantir que chaque réponse soit accompagnée de la citation de sa source (document, date de publication, lien).
- Construire un jeu de test de 30 à 50 questions-réponses et mesurer la fiabilité du système.
- Livrer une interface de démonstration simple permettant d'évaluer le prototype.

Mise à jour (03/09/2026) : Jeu de test de fiabilité construit et exécuté le 3 septembre (30 questions, borne basse de la fourchette prévue) – voir `scripts/mesurer_fiabilite.py`. Résultat : 28/30 (93,3 %), objectif NF2 atteint. Sa construction a elle-même révélé 2 bugs réels dans le système, corrigés avant la mesure finale.

6 Besoins fonctionnels et non fonctionnels

6.1 Besoins fonctionnels

ID	Besoin fonctionnel
F1	L'utilisateur peut poser une question en langage naturel et obtenir une réponse.
F2	Le système distingue automatiquement les questions portant sur un chiffre précis et les questions conceptuelles.
F3	Chaque réponse cite sa source (document, date de publication, lien).
F4	Le système indique explicitement quand il ne trouve pas l'information plutôt que d'inventer une réponse.
F5	Un administrateur peut ajouter ou mettre à jour le contenu indexé.
F6	Le système conserve un historique des questions posées, à des fins d'amélioration continue.

6.2 Besoins non fonctionnels

ID	Exigence non fonctionnelle
NF1	Performance : temps de réponse cible inférieur à 5-8 secondes.
NF2	Fiabilité : taux d'exactitude factuelle supérieur ou égal à 90 % sur le jeu de test, pour les questions chiffrées.
NF3	Traçabilité : 100 % des réponses générées doivent inclure une source vérifiable.
NF4	Sécurité : aucune donnée personnelle traitée ; conformité avec la loi 09-08 relative à la protection des données à caractère personnel.
NF5	Maintenabilité : code documenté et modulaire, permettant l'ajout de nouvelles catégories de contenu sans réécriture complète.

Mise à jour (03/09/2026) : NF2 mesuré et atteint le 3 septembre : 93,3 % (28/30) sur le jeu de test réel, via `scripts/mesurer_fiabilite.py` – calcul 100 % déterministe et hors ligne (aucun appel LLM sur le chemin question chiffrée), vérité terrain établie indépendamment par requête SQL directe sur la base, jamais en réutilisant le module testé comme sa propre référence.

7 Méthodes et démarche

7.1 Démarche de gestion de projet

Fonctionnement en sprints hebdomadaires avec revue de fin de semaine, répartition des rôles au sein du binôme par lot fonctionnel, et point régulier pour arbitrer les points ouverts au fur et à mesure de l'avancement.

7.2 Méthodes techniques envisagées


- Extraction de contenu : scraping structuré dans le respect du robots.txt, parsing HTML, extraction de texte et de tableaux PDF, OCR en secours pour les documents scannés.

Mise à jour (03/09/2026) : L'OCR prévu en secours n'a finalement pas été implémenté (cas réel isolé, coût/risque jugés trop élevés en fin de stage pour une nouvelle dépendance système). À la place : un garde-fou heuristique (`src/extracteur.py`, `_texte_lisible`) détecte et exclut du texte visiblement illisible (police mal mappée) avant chunking, plutôt que de le corriger. Un cas réel de pollution déjà indexée (document #75) a motivé ce correctif, ajouté le 3 septembre. L'OCR reste une piste documentée pour un usage futur si ce cas devient fréquent.

- Traitement du langage : découpage (chunking) respectant la structure des documents, embeddings multilingues capables de traiter le français et extensibles à l'arabe.
- Recherche : recherche hybride dense et lexicale, reranking par cross-encoder pour améliorer la précision du contexte retourné.
- Génération : prompting avec contrainte de grounding strict et citation systématique de la source.
- Évaluation : jeu de questions-réponses de référence, mesure de la fidélité aux sources, de l'exactitude des chiffres et de la pertinence du contexte, inspirée de frameworks du type RAGAS.

8 Conception première (architecture)

L'architecture proposée sépare dès le départ les deux natures de contenu identifiées dans la problématique : le texte non structuré (articles, PDF, glossaire, FAQ) est traité par un pipeline classique de recherche hybride, tandis que les données chiffrées (indicateurs, séries) sont extraites une bonne fois dans une table structurée et interrogées directement – ce qui élimine le risque d'hallucination sur un chiffre officiel. Un routeur de question aiguille chaque requête vers le bon chemin avant que le modèle ne génère une réponse toujours sourcée.



8.1 Détail des modules

Module	Rôle	Flux (entrée → sortie)
1. Scraper	Collecte les pages et PDF des catégories ciblées.	Liste d'URLs → fichiers bruts HTML/PDF + métadonnées de base
2. Extracteur / Parseur	Nettoie le contenu et sépare texte narratif et tableaux de chiffres.	Fichiers bruts → texte propre + tableaux extraits
3. Indexeur texte	Découpe le texte (chunking), calcule les embeddings, indexe.	Texte propre → index vectoriel + index BM25
4. Constructeur base indicateurs	Structure les chiffres clés extraits des tableaux.	Tableaux extraits → table indicateurs (SQL)
5. Routeur	Classifie la question : chiffre précis ou notion/narratif.	Question utilisateur → redirection module 6 ou 7
6. Retrieval + reranking	Recherche hybride (sens + mots-clés), puis tri de pertinence.	Question + index texte → 3 à 5 passages pertinents
7. Lookup structuré	Requête directe et exacte sur la table indicateurs.	Question + filtres → valeur exacte + source
8. Générateur	Rédige la réponse en langage naturel avec citation obligatoire.	Passages ou valeur+source → réponse finale
9. Interface	Affiche la question, la réponse et la source cliquable.	Réponse finale → affichage utilisateur

Mise à jour (03/09/2026) : Module 4 finalement alimenté en priorité par l'API de la Base de Données Statistiques du HCP (`bds.hcp.ma`), et non par extraction de tableaux PDF/XLSX comme prévu ici – source non identifiée au moment de la rédaction de cette fiche. Découverte le 15 juillet en cherchant un accès plus direct aux chiffres officiels : cette API, non documentée publiquement mais librement accessible, s'est avérée plus fiable que l'extraction PDF/XLSX pour les indicateurs curés. Voir ADR 0004 (`docs/adr/0004-api-bds-pour-les-indicateurs.md`). L'extraction PDF/XLSX (module 2) reste utilisée pour le contenu narratif et les documents hors périmètre de la BDS.

Mise à jour (03/09/2026) : Le repli PDF/XLSX pour les indicateurs (envisagé ci-dessus comme source de secours) a finalement été implémenté le 3 septembre (`ConstructeurIndicateurs.structurer`), après qu'un document XLSX réel déjà collecté (« indicateurs trimestriels EMO ») s'est avéré totalement inerte faute de ce chemin : extraction fonctionnelle mais zéro indicateur inséré en base. Reconnaît un motif précis (dictionnaire Code/Nom/Unité + tableau de données), testé sur les vraies données (1728 lignes, valeurs exactes, aucune régression sur le jeu de fiabilité). Une tentative de généraliser à *tout* fichier Excel du HCP a été explorée – fichiers réels téléchargés et ouverts pour comparer – puis abandonnée : l'« Annuaire Statistique du Maroc » s'est avéré être une archive de 23 fichiers Excel × jusqu'à 34 feuilles bilingues mises en page pour l'impression, sans dictionnaire ni structure programmatique – aucun format Excel unique chez le HCP, donc pas de parseur générique universel sûr. Limite assumée et documentée plutôt que contournée (voir `JOURNAL.md`, 03/09).

8.2 Modèle de données

Table	Champs principaux
documents	id, url, titre, date_publication, langue, categorie, type (html/pdf)
chunks	id, document_id, texte du morceau, position, embedding (vecteur)
indicateurs	id, nom_indicateur, valeur, unite, periode, region, document_source

8.3 Scénarios d'exécution (exemples)

Question chiffrée – « **Quel est le taux de chômage actuel ?** » : Interface → Routeur (détecte « chiffre ») → Lookup structuré dans la table indicateurs → valeur exacte + source → Générateur rédige une phrase courte et sourcée → Interface affiche la réponse.

Question conceptuelle – « **C'est quoi le RGPH ?** » : Interface → Routeur (détecte « notion ») → Retrieval hybride dans l'index texte → Reranking garde les meilleurs passages → Générateur rédige une explication sourcée → Interface affiche la réponse.

8.4 Choix technologiques proposés

Composant	Techno proposée
Scraping	requests + BeautifulSoup
Extraction PDF / tableaux	PyMuPDF ou pdfplumber, Camelot pour les tableaux
Embeddings	Modèle multilingue open source (ex. BGE-M3)
Index vectoriel	Chroma (simple à installer, suffisant pour un prototype)
Recherche mots-clés	BM25 (ex. librairie rank_bm25)
Reranking	Cross-encoder open source (ex. bge-reranker)
Base indicateurs	SQLite
LLM de génération	À définir – point ouvert, voir section 11
Interface de démonstration	Streamlit

Mise à jour (03/09/2026) : Choix confirmés en pratique : extraction PDF/tableaux par pdfplumber seul (extract_tables intégré suffisant – PyMuPDF et Camelot, envisagés ici, jamais utilisés au final). LLM de génération tranché le 21 juillet : **Mistral** (mistral-small-latest, API externe, tier gratuit), retenu après comparaison avec Google Gemini et Groq pour la qualité du français. Voir ADR 0002 (docs/adr/0002-stack-technique-prototype.md) pour le détail de la comparaison. Le reste de la stack (BGE-M3, Chroma, rank-bm25, SQLite, Streamlit) confirmé sans changement.

8.5 Points de robustesse à prévoir

- Si le routeur se trompe de catégorie, prévoir un filet de sécurité : si le lookup structuré ne trouve rien, basculer automatiquement sur le retrieval texte.
- Si aucune source pertinente n'est trouvée, la réponse doit être « information non disponible dans les sources » plutôt qu'une réponse générée sans base.

9 Analyse des risques

Les risques principaux identifiés à ce stade et leurs mesures de mitigation associées :

Risque	Impact	Probabilité	Mitigation
Hallucination sur un chiffre officiel	Élevé	Moyenne	Séparation stricte indicateurs/texte, grounding strict, citation obligatoire
Délai très serré (4-5 semaines)	Élevé	Élevée	Périmètre volontairement restreint, priorisation des fonctionnalités coeur

Risque	Impact	Probabilité	Mitigation
Qualité variable de l'extraction PDF	Moyen	Moyenne	Curation manuelle des indicateurs clés en phase 1, OCR en secours
Dépendance à une API LLM externe	Moyen	Moyenne	Clarifier avec l'encadrante, prévoir repli open source
Contenu bilingue FR/AR complexifiant l'indexation	Faible pour le prototype	Faible (AR hors scope V1)	Français prioritaire, arabe en extension

Mise à jour (03/09/2026) : Risque « qualité variable de l'extraction PDF » concrétisé : un document réellement en base (police arabe legacy) produisait des symboles bruts indexés. Mitigation réelle appliquée le 3 septembre : garde-fou de détection/exclusion (voir encadré section 6), et non l'OCR envisagé ici – l'OCR reste une piste documentée mais non implémentée.

10 Critères de réussite

- Le prototype répond correctement, avec source citée, à au moins 80 à 90 % des questions du jeu de test.
- La démonstration fonctionne de bout en bout sur les catégories de contenu retenues.
- Le code est versionné, documenté et reproductible par un tiers.
- Le rapport de stage et la présentation finale sont prêts avant la fin du stage.

Mise à jour (03/09/2026) : Critère de fiabilité atteint et dépassé : 93,3 % (28/30) mesuré le 3 septembre, contre 80 à 90 % visé ici. Code versionné (git, commits locaux) et suite de tests automatisée à 224/224 à la même date.

11 Hypothèses de travail et points à valider

Pour ne pas bloquer l'avancement, les hypothèses par défaut suivantes sont retenues dès maintenant ; elles seront confirmées ou ajustées lors du prochain point avec l'encadrante.

- Périmètre : on travaille sur les catégories définies en section 2 ; à confirmer ou élargir plus tard.
- Hébergement : on utilise une API LLM externe pour le prototype (moins de friction) ; la question de la souveraineté des données sera soulevée avant toute mise en production.
- Utilisateurs : on conçoit pour le grand public (cas le plus exigeant en clarté), transposable à un usage interne.
- Langue : français prioritaire pour le prototype.
- Données internes : on suppose qu'aucune base d'indicateurs interne n'est disponible et on construit depuis le site public ; à ajuster si le contraire est confirmé.
- Budget et accès API : on utilise un accès de test en attendant une clarification budgétaire.
- Validation : toute réponse portant un chiffre est vérifiée manuellement pendant la phase de test.
- Portée après le stage : prototype figé livré en fin de stage, mise à jour continue hors périmètre.

Mise à jour (03/09/2026) : Budget/accès API résolu : Mistral, tier gratuit, validation encadrante le 21 juillet (voir ADR 0002). Validation manuelle systématique complétée (non remplacée) par une mesure automatisée : `scripts/mesurer_fiabilite.py`, 30 questions à vérité terrain indépendante, exécutable à tout moment sans intervention manuelle.

12 Planning proposé

Planning ciblé sur 5 semaines (livraison début août), avec une marge de sécurité jusqu'à fin août en cas d'aléa.

Semaine	Dates	Objectifs clés
S1	7 – 13 juil.	Validation du périmètre, choix de la stack, script de scraping sur les catégories ciblées, extraction d'un échantillon test.
S2	14 – 20 juil.	Pipeline d'ingestion complet (HTML + PDF + tables), constitution de la table structurée des indicateurs, génération des embeddings et indexation.
S3	21 – 27 juil.	Recherche hybride + reranking, routeur de question, génération avec citation systématique, premiers tests de bout en bout.
S4	28 juil. – 3 août	Interface de démonstration, constitution du jeu de test (30-50 questions), mesure de fiabilité, itération sur les points faibles.
S5	4 – 10 août	Finalisation, documentation, préparation du rapport et de la démonstration finale (cible de fin de projet).
Marge	jusqu'à fin août	Réserve en cas de retard, ou extension (support arabe, amélioration interface) si le calendrier le permet.

Mise à jour (03/09/2026) : Calendrier réellement dépassé : la marge prévue jusqu'à fin août n'a pas suffi – le jeu de test de fiabilité et la finalisation (Sprint 5) n'ont été clôturés que le 3 septembre. Écart assumé : pas de régression sur le périmètre, juste un allongement de la phase de finalisation/mesure.

13 Glossaire

Terme	Définition
RAG (Retrieval-Augmented Generation)	Méthode qui récupère des documents pertinents avant de générer une réponse, pour ancrer le modèle dans des sources vérifiées plutôt que dans sa seule mémoire d'entraînement.
LLM (Large Language Model)	Modèle de langage entraîné sur de grands volumes de texte, capable de comprendre et générer du langage naturel.
Embedding	Représentation numérique (vecteur) d'un texte qui capture son sens, permettant de comparer des textes par similarité sémantique.
Chunking	Découpage d'un document en morceaux (chunks) de taille gérée, avant indexation.
Index vectoriel	Base de données spécialisée dans le stockage et la recherche rapide de vecteurs (embeddings) par similarité.
BM25	Algorithme classique de recherche par mots-clés, basé sur la fréquence des termes.

Terme	Définition
Reranking	Étape qui retient les documents candidats récupérés pour ne garder que les plus pertinents, à l'aide d'un modèle plus précis.
Grounding	Contrainte imposée au LLM de ne répondre qu'à partir des informations fournies dans le contexte récupéré.
Hallucination	Génération par un LLM d'une information plausible mais fausse ou non vérifiée.
MCD / MLD	Modèle Conceptuel de Données / Modèle Logique de Données – représentations formelles (méthode Merise) des entités, attributs et relations d'une base de données relationnelle.