

Bilan du Sprint 1

Cadrage, conception et premiers scripts – Système RAG pour
hcp.ma

Structure d'accueil : Haut-Commissariat au Plan (HCP), Direction des Systèmes
d'Information Statistiques

Binôme : Ayman El Baida et Saad Mesbah

Période couverte : 7 – 15 juillet 2026 (Sprint 1)

Document rédigé le 15 juillet 2026 – support de suivi pour l'encadrante et le rapport de stage

Table des matières

1	Objectif du Sprint 1	2
2	Livrables produits	2
2.1	Documents de cadrage et de conception	2
2.2	Code et infrastructure	2
3	Tests réels effectués	2
4	Erreurs rencontrées et solutions apportées	3
5	Décision de recadrage : ADR 0003	4
6	État du pipeline à l'issue du Sprint 1	4
7	Points à valider avec l'encadrante	4
8	Transition vers le Sprint 2	5

1 Objectif du Sprint 1

Le Sprint 1 (7 – 13 juillet 2026, prolongé au 15 juillet) visait à poser des bases solides avant d’attaquer le pipeline complet : formaliser le cadrage et la conception du projet, mettre en place un squelette de code aligné sur cette conception, et surtout obtenir un premier retour du terrain en testant les premiers scripts sur de vraies pages du site hcp.ma. Ce dernier point s’est révélé le plus riche d’enseignements : plusieurs hypothèses de conception initiales se sont avérées incomplètes ou fausses à l’épreuve de données réelles, ce qui a conduit à des corrections documentées plutôt qu’à des ajustements silencieux.

2 Livrables produits

2.1 Documents de cadrage et de conception

Document	Contenu
Fiche de cadrage (fiche_cadrage_v4.pdf)	Nature et périmètre, problématique, objectifs, besoins fonctionnels/non fonctionnels, architecture, risques, planning en 5 sprints, glossaire.
Dossier de conception (conception_uml_v3.pdf)	7 diagrammes UML/Merise avec analyse : cas d’utilisation, MCD, MLD, classes, deux séquences (question chiffrée / conceptuelle), activité.
ADR 0001	Décision fondatrice : séparation stricte texte narratif / indicateurs chiffrés, pour éliminer le risque d’hallucination sur les chiffres officiels.
ADR 0002	Choix de la stack technique du prototype (scraping, extraction, embeddings, index, interface).
ADR 0003	Décision prise en cours de Sprint 1, suite aux tests réels : le RAG s’appuie exclusivement sur les publications PDF/XLSX de hcp.ma, jamais sur le texte des pages HTML (voir section 5).

2.2 Code et infrastructure

Squelette de dépôt Git opérationnel (module par module, aligné sur le diagramme de classes), schéma de base de données SQL (db/schema.sql), 6 tests automatisés (tous verts), et une liste de 27 URLs réelles réparties sur les 3 catégories ciblées (Économie, Marché du travail, Population & démographie) servant d’échantillon de test tout au long du sprint.

3 Tests réels effectués

Contrairement à une simple relecture de code, chaque étape du pipeline a été exécutée sur les 27 vraies pages hcp.ma, ce qui a permis de découvrir des problèmes invisibles sur le papier.

Test	Méthode	Résultat
1. Scraper seul (métadonnées)	Récupération des 27 pages HTML, extraction titre/date	27/27 pages récupérées, 27/27 titres, 25/27 dates au premier essai (27/27 après correctif, voir section 4)
2. Extracteur HTML	Extraction du texte narratif et des tableaux des 27 pages	0 caractère de texte utile sur plusieurs pages ; tableaux détectés = menus de navigation, pas des données

Test	Méthode	Résultat
3. Détection et téléchargement PDF/XLSX (1 ^{er} essai)	Scraper étendu pour repérer et télécharger les pièces jointes de chaque page	1 PDF téléchargé et extrait avec succès (8 000+ caractères, 3 tableaux) – preuve que le pipeline fonctionne, mais version arabe au lieu de française
4. Même test, après correctif langue	Nouvelle exécution sur la même page	PDF français correctement téléchargé, 8 435 caractères de texte réel et 3 tableaux de données économiques exploitables
5. Run complet sur les 27 pages	Exécution de bout en bout, avec téléchargement des pièces jointes	Le premier run plante en cours de route (voir section 4) ; après correctifs, un run complet aboutit, avec du contenu PDF réel extrait pour la majorité des publications

4 Erreurs rencontrées et solutions apportées

Six problèmes concrets ont été identifiés grâce aux tests réels. Cinq ont été résolus dans le Sprint 1 ; le sixième reste ouvert et devient la première tâche du Sprint 2.

Problème	Cause	Solution
2 dates de publication non détectées sur 27	Texte encodé en Unicode décomposé (accent séparé de la lettre) sur certaines pages, cassant la reconnaissance de motif	Normalisation systématique du texte en Unicode composé (NFC) avant l'analyse
Extraction HTML inexploitable (0 caractère, menus pris pour des tableaux)	Le corps des articles hcp.ma n'est pas systématiquement structuré en balises <p>, et les menus de navigation sont parfois rendus en balises <table>	Recadrage du périmètre : le HTML n'est plus une source de données pour le RAG, seulement un moyen de repérer les liens de téléchargement et le titre/date (ADR 0003)
PDF téléchargé dans la mauvaise langue (arabe au lieu de français)	Le champ langue du document était fixé en dur à « fr » sans vérification, alors que chaque publication existe en deux versions (_Fr / _Ar)	Détection automatique de la langue à partir des indices présents dans les liens, avec filtrage des pièces arabes par défaut (hors périmètre V1)
Script interrompu par une erreur non gérée (PDFSyntaxError : No /Root object)	Un lien détecté comme menant à un PDF pointait en réalité vers un contenu invalide (page d'erreur ou redirection), et rien ne vérifiait le contenu réel avant de le traiter comme un PDF	Vérification des nombres magiques du fichier téléchargé (signature %PDF- ou PK) avant traitement, et gestion d'exception pour qu'un document invalide n'interrompe plus l'ensemble du run
Fichiers de test qui s'écrasaient entre eux	Le script de test nommait chaque fichier de sortie d'après le titre du document, or une page HTML et sa pièce jointe héritent du même titre	Nom de fichier rendu unique en ajoutant le type de document et un numéro d'ordre

Problème	Cause	Solution
Sur-détection des pièces jointes (5 à 8 PDF détectés pour une seule page, au lieu de 1 ou 2)	L'heuristique de détection des liens de téléchargement est trop large : elle repère aussi des liens vers d'autres publications listées ailleurs sur la page (encart « dernières publications »)	Ouvert – à corriger en priorité en début de Sprint 2, avant l'indexation réelle, pour éviter d'associer du contenu au mauvais titre/catégorie

5 Décision de recadrage : ADR 0003

Le test 2 (section 3) a fait apparaître que l'extraction du texte HTML n'était pas seulement perfectible mais fondamentalement hors sujet : les pages HTML de `hcp.ma` ne portent qu'un résumé court, les données réelles (tableaux complets, séries chiffrées, rapports intégraux) se trouvant exclusivement dans des fichiers PDF et XLSX téléchargeables. Ce constat, confirmé par le périmètre exact du projet tel que précisé en cours de sprint, a conduit à une décision d'architecture actée dans l'ADR 0003 : le système RAG s'indexe uniquement sur les publications PDF/XLSX, le HTML servant seulement d'outil de découverte (liens de téléchargement) et de source de métadonnées (titre, date). Cette clarification évite de continuer à investir du temps dans la correction d'une extraction HTML qui n'a plus lieu d'être, et recentre le Sprint 2 sur ce qui compte réellement.

6 État du pipeline à l'issue du Sprint 1

Module	Statut	Détail
Scraper	Fonctionnel, testé en réel	Collecte les pages HTML, détecte et télécharge les pièces jointes PDF/XLSX, filtre la langue
Extracteur	Fonctionnel pour PDF/XLSX, testé en réel	Branches <code>pdfplumber</code> et <code>openpyxl</code> opérationnelles ; branche HTML conservée dans le code mais non utilisée pour l'indexation
IndexeurTexte, ConstructeurIndicateurs, Routeur, RetrievalReranker, LookupStructure, Generateur, Interface	Squelette (non implémenté)	Signatures alignées sur le diagramme de classes, implémentation prévue en Sprint 2 et 3

7 Points à valider avec l'encadrante

- Choix du LLM de génération : API externe autorisée ou modèle hébergé en interne ? Point bloquant pour le Sprint 3.
- Confirmation du périmètre : RAG exclusivement sur les publications PDF/XLSX en français, arabe hors périmètre V1.
- Hébergement cible du prototype et utilisateurs visés.
- Disponibilité de données internes complémentaires, budget d'accès à une API externe si retenue.

8 Transition vers le Sprint 2

Le Sprint 1 est considéré comme clôturé : les scripts de collecte tournent sur un vrai échantillon et produisent des documents exploitables, et les problèmes rencontrés ont été traités et documentés plutôt que contournés. Le Sprint 2 (14 – 20 juillet) s'ouvre sur un périmètre précis : transformer les publications PDF/XLSX collectées en données indexées, de bout en bout.

#	Tâche
1	Corriger la sur-détection des pièces jointes (section 4) avant toute indexation
2	Valider plus largement l'extraction PDF (<code>pdfplumber</code>) et XLSX (<code>openpyxl</code>) sur l'ensemble des 27 pages
3	Chunking et embeddings du texte extrait (<code>IndexeurTexte.indexer</code>), en excluant explicitement les documents de type HTML
4	Indexation hybride Chroma (sémantique) + BM25 (lexical)
5	Curation des 15 à 20 indicateurs clés à partir des tableaux PDF/XLSX (<code>ConstructeurIndicateurs.structurer</code>)
6	Script d'insertion en base SQLite (<code>db/schema.sql</code>)

Definition of done du Sprint 2 : les documents PDF/XLSX collectés en Sprint 1 sont indexés de bout en bout (texte et indicateurs) et interrogeables par script, sans qu'aucun contenu HTML ne soit indexé.